

Лабораторная работа №2. Извлечение и обработка данных из стороннего web-сервера с помощью Python-приложения

Цель работы: Получение навыков работы с протоколом HTTP: построение запросов к удаленному веб-серверу для получения содержимого веб-страницы. Получение навыков обработки и извлечения данных из HTML-страницы при помощи Python-библиотек.

Задание на работу:

1. Установить необходимые Python-библиотеки: **requests**.
2. Перехватить экземпляр запроса к веб-сайту <https://ruz.spbstu.ru>. Для этого необходимо использовать утилиту **burpsuite**. Изучить заголовки запроса.
3. Включив фильтрацию результатов поиска (по номеру группы/по преподавателю/по аудитории), изучить то, как меняется URL запроса. Сделать выводы о параметрах в URL.
4. Изучить HTTP-трафик, перехваченный при взаимодействии с целевым веб-сервером. Составить список конечных точек API, которые необходимы для извлечения расписания с заданным фильтром (по номеру группы/по преподавателю/по аудитории).
5. Описать последовательность и логику запросов к API, которые необходимы для извлечения расписания.
6. С помощью библиотеки **requests** выполнить GET-запрос к одной из конечных точек API. Проанализировать принцип передачи параметров в запросе, описать формат данных, содержащихся в ответе.
7. Используя библиотеку **requests**, извлечь из тела ответа расписание в формате: название предмета, время, аудитория, преподаватель, тип занятия (практика/лекция и т.п.), группа (либо список групп). Последовательность запросов должна воспроизводить изученную на предыдущих шагах логику работы веб-сайта.

Для автоматизированного тестирования разработанной программы необходимо реализовать перечисленные ниже функции:

- `get_teacher_schedule` - функция, выводящая расписание по преподавателю. Функция принимает в качестве аргументов: `teacher_name` - полные ФИО преподавателя (например, “Иванов Иван Иванович”), `date` - день, на который необходимо получить расписание (например, “2026-02-20”);

- `get_room_schedule` - функция, выводящая расписание по аудитории. Функция принимает в качестве аргументов: `building_name` - название корпуса (например, “Главное здание”), `room_name` - название аудитории (например, “175”), `date` - день, на который необходимо получить расписание (например, “2026-02-20”);

- `get_group_schedule` - функция, выводящая расписание по группе. Функция принимает в качестве аргументов: `group_name` - полный номер группы, `date` - день, на который необходимо получить расписание.

В качестве возвращаемого значения необходимо вернуть строку в формате:

“Time:{ВРЕМЯ_НАЧАЛА_ЗАНЯТИЯ}-{ВРЕМЯ_ОКОНЧАНИЯ_ЗАНЯТИЯ}\nSubject:{НАЗВАНИЕ_ПРЕДМЕТА}\nType:{ТИП_ЗАНЯТИЯ}\nTeacher:{ФИО_ПРЕПОДАВАТЕЛЯ}\nGroups:{СПИСОК_ГРУПП}\nPlace:{НАЗВАНИЕ_АУДИТОРИИ}\n”. Значения в фигурных скобках необходимо заменить на соответствующие значения из полученных данных. В случае, если одно из перечисленных значений отсутствует в расписании (например, ФИО преподавателя), вместо него необходимо указать строку “None”. В случае, если одно из полей имеет более одного значения (например, номер группы), необходимо перечислить их, разделяя запятой без пробелов. Название аудитории необходимо указывать без названия корпуса.

Пример вывода программы (расписание по преподавателю на 20.02.2026):

```
Time:10:00-11:40
Subject:Цифровая аналитика
Type:Практика
Teacher:Писков Александр Александрович
Groups:5151001/40003
```

Place:336

Time:12:00-13:40

Subject:Цифровая аналитика

Type:Практика

Teacher:Писков Александр Александрович

Groups:5151003/40001

Place:336

Time:18:00-19:40

Subject:Объектно-ориентированное программирование

Type:Доп.сессия. Зачет

Teacher:Писков Александр Александрович

Groups:5131001/30501

Place:201

Time:18:00-19:40

Subject:Объектно-ориентированное программирование

Type:Доп.сессия. Зачет

Teacher:Писков Александр Александрович

Groups:5131001/30502

Place:201

В случае, если на указанную дату нет расписания, необходимо вернуть объект None.

8. Написать отчет о проделанной работе.

9. Ответить на контрольные вопросы:

1) Какие виды HTTP-запросов существуют, для чего нужен каждый из них? Какие данные можно получить при отправке GET-запроса к web-ресурсу?

2) Что такое DOM-объект, для чего он необходим? Какие библиотеки и функции были использованы при анализе HTML-страницы?

3) По умолчанию в библиотеке requests включена проверка SSL-сертификатов. Что необходимо сделать, чтобы запросы к защищенным страницам работали корректно?

4) Из каких частей состоит HTTP-запрос? Какие способы передачи параметров в запрос существуют?